

PROJETS NLP1 - M1S2 - FDIA - UVBF

Projet No 1 : Reconnaissance d'Entités Nommées spécifiques à un domaine

Objectif

Développer un modèle de reconnaissance d'entités nommées (NER) spécifique à un domaine en utilisant spaCy. L'objectif est de capturer et annoter les entités pertinentes à l'aide de motifs regex et d'un modèle personnalisé.

Étapes essentielles

1. Collecte des données :

- Constituer un corpus de textes spécifiques au domaine d'intérêt (ex: L'IA, pour détecter des termes comme, Machine Learning, Unsupervised , NN, RNN, etc.).

2. Prétraitement des données :

- Nettoyer le texte en supprimant les stopwords et en appliquant des techniques de lemmatisation.

3. Développement de motifs Regex :

- Créer des motifs regex pour détecter certaines entités simples (par exemple, des dates, des codes, etc.).

4. Annotation manuelle des données :

- Définir les entités nommées que votre modèle devrait pouvoir reconnaître. Ces entités doivent être en dehors des classiques comme PER, ADJ, etc.

5. Ajouter cette nouvelle couche a EntityRuler de spaCy Personnalisé :

- Utiliser les annotations manuelles pour construire le modèle spaCy NER.

6. Évaluation du modèle :

- Évaluer la performance du modèle sur un jeu de données de test et affiner les motifs regex et les annotations pour améliorer la précision.

Disponibilisez le tout sur une interface Streamlit pour les tests

Projet No 2 : Comparaison des techniques de vectorisation

Objectif

Appliquer différentes techniques de vectorisation sur un corpus thématique et comparer leurs performances en termes de similarité entre les documents et une liste de mots clés.

Étapes essentielles

1. Constitution du corpus thématique :

- Collecter automatiquement des articles en ligne en utilisant le web scraping.
- Faire ressortir les techniques utilisées pour constituer les mots clés de collecte

2. Prétraitement des données :

- Nettoyer les articles collectés (tokenisation, suppression des stopwords, lemmatisation, etc.).

3. Vectorisation des données :

- Appliquer plusieurs techniques de vectorisation, telles que :
 - Bag of Words (BoW)
 - Term Frequency-Inverse Document Frequency (TF-IDF)
 - Word2Vec
 - BERT embeddings

4. Calcul de la similarité :

- Calculer la similarité entre les articles et la liste de mots clés en utilisant les vecteurs générés.

5. Évaluation et comparaison :

- Comparer les 20 premiers documents en fonction de leur similarité avec les mots clés pour chaque technique de vectorisation.
- Évaluer la qualité de chaque technique de vectorisation en fonction de la pertinence des documents sélectionnés.

Disponibiliser votre application sur une interface Streamlit, offrant le choix du vectorisation, affiche les TopX documents pertinents (x pouvant être fixé par l'utilisateur).

Projet No 3 : Modélisation de sujets avec différentes techniques

Objectif

Appliquer plusieurs techniques de modélisation de sujets sur un corpus et interpréter les résultats pour évaluer la qualité des sujets extraits.

Étapes essentielles

1. Constitution du corpus :

- Utiliser des ensembles de données publics pour créer un corpus thématique.
Vous prendre des articles de presse en ligne comme l'AIB,

2. Prétraitement des données :

- Nettoyer le texte en supprimant les stopwords, la ponctuation et en appliquant des techniques de lemmatisation.
- 3. **Application de différentes techniques de modélisation de sujets :**
 - Utiliser des techniques telles que :
 - Latent Dirichlet Allocation (LDA)
 - Non-negative Matrix Factorization (NMF)
 - BERTopic
- 4. **Interprétation des résultats :**
 - Analyser les sujets extraits par chaque technique.
 - Identifier les mots clés associés à chaque sujet et interpréter le thème général.
- 5. **Comparaison des techniques :**
 - Comparer la cohérence et la pertinence des sujets extraits par chaque technique.
 - Discuter des avantages et des inconvénients de chaque méthode de modélisation de sujets.

Proposez une application Streamlit avec des paramètres pour le choix du type de modélisation, de visualisation, etc.

Projet No 4 : Analyse de sentiment avec approches comparatives

Objectif Développer et comparer différentes approches d'analyse de sentiment (lexicale, statistique, et neuronale) sur des corpus francophones.

Étapes essentielles

1. **Collecte de données** : Scraper des avis clients, commentaires de réseaux sociaux ou articles de presse
2. **Prétraitement unifié** : Pipeline standardisé (tokenisation, nettoyage, lemmatisation)
3. **Approche lexicale** : Utilisation de dictionnaires de polarité et création de règles
4. **Approche statistique** : Classification avec Naive Bayes, SVM, régression logistique
5. **Approche neuronale** : Fine-tuning de modèles pré-entraînés (CamemBERT, FlauBERT)
6. **Évaluation comparative** : Métriques de performance et analyse des erreurs

Interface Streamlit pour tester les différentes approches sur des textes utilisateurs.

Projet No 5 : Classification automatique d'articles de Presse

Objectif Construire un système de classification automatique d'articles de presse en catégories thématiques en utilisant différentes techniques de vectorisation.

Étapes essentielles

1. **Scraping ciblé** : Collecte d'articles depuis des sites d'actualités burkinabe (AIB, lefaso.net, etc.)
2. **Annotation manuelle** : Définition et étiquetage des catégories (politique, économie, sport, culture, etc.)
3. **Vectorisation multiple** : Application de BoW, TF-IDF, Word2Vec, et embeddings BERT
4. **Classification comparative** : Tests avec différents algorithmes (Naive Bayes, SVM, réseaux de neurones)
5. **Optimisation** : Tuning des hyperparamètres et sélection du meilleur modèle
6. **Déploiement** : Interface de classification en temps réel

Application permettant l'upload d'articles et leur classification automatique avec scores de confiance.

Projet No 6 : Détecteur de plagats avec mesures de similarité

Objectif Créer un système de détection de similarité entre documents en explorant différentes métriques et seuils de détection.

Étapes essentielles

1. **Constitution du corpus** : Collection de documents académiques, articles, et contenus web
2. **Prétraitement avancé** : N-grammes, skip-grammes, et normalisation de texte
3. **Métriques de similarité** : Implémentation de similarité cosinus, Jaccard, distance de Levenshtein
4. **Optimisation des seuils** : Détermination empirique des seuils de détection
5. **Visualisation** : Matrices de similarité et graphiques de clusters
6. **Validation** : Tests sur des cas connus de plagiat et de contenus originaux

Outil Streamlit pour comparer des documents et visualiser les similarités détectées.

Projet No 7 : Générateur de résumés automatiques multi-techs

Objectif Développer un système de résumé automatique combinant approches extractives et abstractives pour différents types de documents.

Étapes essentielles

1. **Corpus diversifié** : Articles de presse, documents académiques, rapports techniques
2. **Résumé extractif** : Implémentation de TextRank, scoring TF-IDF, et sélection de phrases clés
3. **Résumé abstractif** : Utilisation de modèles de génération (T5, mBART)
4. **Métriques d'évaluation** : ROUGE scores, cohérence, et évaluation humaine

5. **Interface adaptative** : Contrôle de la longueur et du style de résumé
6. **Optimisation** : Comparaison et hybridation des approches

Application permettant de résumer des textes avec choix de la méthode et paramètres personnalisables.

Projet No 8 : Chatbot FAQ intelligent avec NER et classification d'intentions - Appliquer sur les besoins des étudiants de l'UV-BF

Objectif:

Construire un chatbot capable de répondre aux questions fréquentes en utilisant la NER pour extraire les entités et classifier les intentions des utilisateurs.

Étapes essentielles

1. **Base de FAQ** : Constitution d'une base de questions-réponses dans un domaine spécifique
2. **NER personnalisé** : Définition d'entités spécifiques au domaine (produits, services, lieux)
3. **Classification d'intentions** : Entraînement d'un modèle pour identifier le type de question
4. **Matching intelligent** : Système de correspondance entre questions et réponses
5. **Génération de réponses** : Templates de réponses avec insertion d'entités détectées
6. **Apprentissage continu** : Mécanisme de feedback et amélioration

Chatbot déployé avec interface conversationnelle et tableau de bord d'analytics.

Projet No 9 : Analyseur de tendances sur les commentaires des utilisateurs (lefaso.net) - il s'agit de voir si les commentaires sont neutres et/ou libres

Objectif

Développer un système d'analyse de tendances et d'opinions sur les réseaux sociaux en combinant scraping, preprocessing, et analyse de sentiment.

Étapes essentielles

1. **Collecte de données** : Scraping de données publiques de réseaux sociaux ou forums
2. **Nettoyage spécialisé** : Traitement des emojis, hashtags, mentions, et langage informel
3. **Détection de tendances** : Analyse de fréquence temporelle des mots-clés et n-grammes
4. **Analyse de sentiment** : Classification des opinions (positif, négatif, neutre)

5. **Visualisations** : Graphiques temporels, nuages de mots, et tableaux de bord
6. **Alertes automatiques** : Système de notification pour les pics de mention

Interface de monitoring avec visualisations interactives et exports de rapports.

Projet No 10 : Système de recommandation de contenu textuel

Objectif

Créer un système de recommandation basé sur l'analyse de contenu textuel et la modélisation des préférences utilisateurs.

Étapes essentielles

1. **Corpus de contenu** : Articles, livres, ou documents dans un domaine spécifique
2. **Profiling utilisateur** : Modélisation des préférences basée sur l'historique de lecture
3. **Analyse de contenu** : Extraction de features textuelles (topics, entités, sentiment)
4. **Similarité de contenu** : Calcul de similarité entre documents et profils utilisateurs
5. **Algorithmes de recommandation** : Implémentation de filtrage collaboratif et basé sur le contenu
6. **Évaluation** : Métriques de précision, rappel, et satisfaction utilisateur